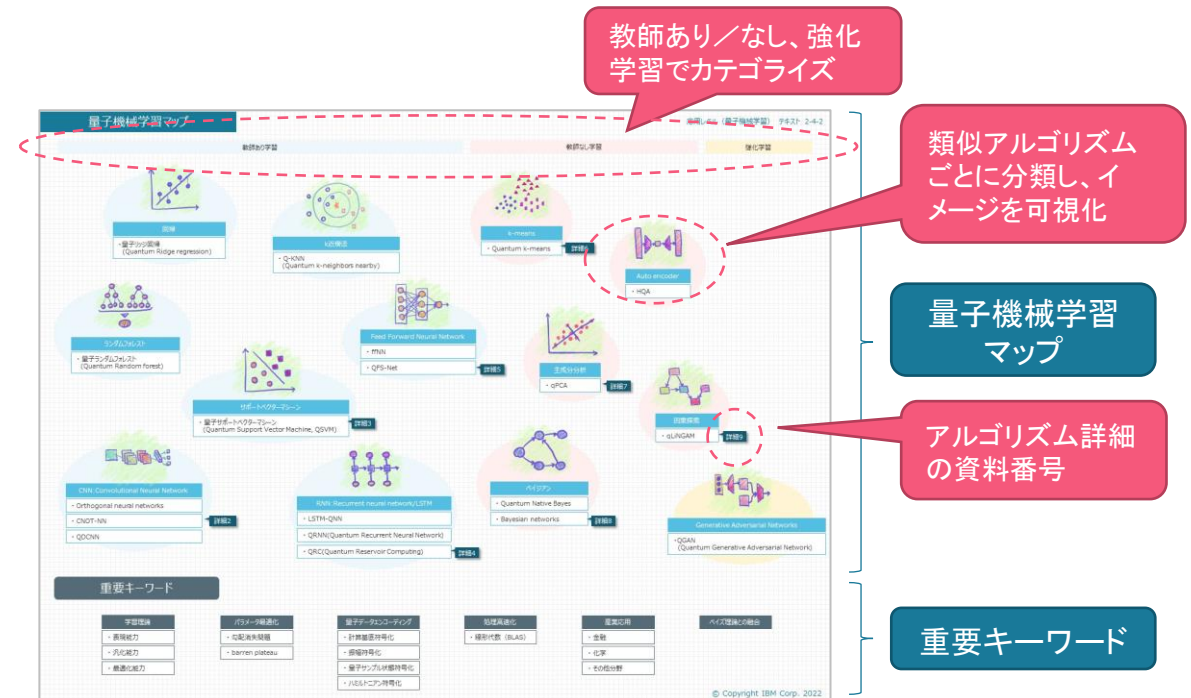


1 量子機械学習マップとは

- 量子機械学習マップとは：
量子機械学習におけるアルゴリズム(量子アルゴリズム)と、量子アルゴリズムを構成している関連技術を整理した俯瞰図である。
- 課題認識：
量子機械学習には、「量子コンピュータを用いた機械学習」と「量子の知見に基づいた機械学習」の2種類があり(テキスト 1-1)、それぞれ研究開発が行われている段階にある。しかし、これらの情報は発展途上にあるため体系的な整理がされておらず、量子機械学習の全体を捉えることが難しい状況にある。(情報が散乱している)
- マップの作成：
量子機械学習マップは、量子機械学習の現況を全体として俯瞰できる情報を一枚絵にまとめることで、AI人材が量子機械学習の全体を捉えられるようにすることを目的として「量子機械学習マップ」を作成する。

2 量子機械学習マップ概要


- 量子機械学習マップは、量子機械学習で用いられる「量子アルゴリズム」と、それに関連する「重要キーワード」で構成している。
 - ✓ 量子アルゴリズムは、カテゴリごとにマップ上に配置した。
 - ✓ 重要キーワードは、さまざまな量子アルゴリズムが新たに開発されている現状において、アルゴリズムをきちんと理解するために知っておくべきキーワードを中心に列挙している。
- さらに、量子アルゴリズムの詳細説明(2-4-3-2~)を個別に作成。詳細説明を作成していないものは参照論文(2-4-3-1)をリストアップ。



教師あり学習


教師なし学習

強化学習




回帰

・Quantum Ridge regression




k近傍法

・ Q-KNN
(Quantum k-neighbors nearby)

k-means


・ Quantum k-means

詳細6




Auto encoder

・ HQA



ランダムフォレスト

・ 量子ランダムフォレスト
(Quantum Random forest)

Feed Forward Neural Network

・ ffNN

・ QFS-Net
(Quantum fully self-supervised neural networks)


詳細5



主成分分析

・ qPCA
(quantum Principal Component Analysis)

詳細7



サポートベクターマシーン

・ QSVM (Quantum Support Vector Machine)


詳細3



CNN:Convolutional Neural Network

・ Orthogonal neural networks
・ CNOT-NN (CNOT Neural Networks)
・ QDCNN

詳細2




RNN:Recurrent neural network/LSTM

・ LSTM-QNN

・ QRNN (Quantum Recurrent Neural Network)

・ QRC (Quantum Reservoir Computing)

詳細4




ベイジアン


・ Quantum Native Bayes

・ Bayesian networks

詳細8



Generative Adversarial Networks

・ QGAN
(Quantum Generative Adversarial Network)

因果探索

・ qLiNGAM

詳細9

重要キーワード

学習理論

・ 表現能力
・ 汎化能力
・ 最適化能力

パラメータ最適化

・ 勾配消失問題
・ barren plateau

量子データエンコーディング

・ 計算基底符号化
・ 振幅符号化
・ 量子サンプル状態符号化
・ ハミルトニアン符号化

処理高速化

・ 線形代数（BLAS）

産業応用

・ 金融
・ 化学
・ その他分野

ベイズ理論との融合

量子機械学習マップ上のアルゴリズム詳細は個別に説明資料を作成している。
当資料は個別作成のないものに関する参照論文を掲載する。

1 量子リッジ回帰

量子リッジ回帰(Quantum ridge regression)

An improved quantum algorithm for ridge regression Chao-Hua Yu, Fei Gao, Qiao-Yan Wen(2017) arXiv:1707.09524

2 Q-KNN

Q-KNN(Quantum k-neighbors nearby)

Quantum Algorithm for K-Nearest Neighbors Classification Based on the Metric of Hamming Distance Yue Ruan, Xiling Xue, Heng Liu, Jianing Tan & Xi Li (2017)

3 量子ランダムフォレスト

量子ランダムフォレスト(Quantum Random Forest)

Khadiev, K., Safina, L.: The quantum version of random forest model for binary classification problem. CEUR Workshop Proceedings 2842, 30–35 (2021)

4 Auto encoder

HQA

M. Srikumar, C. D. Hill, L. C. L. Hollenberg, Clustering and enhanced classification using a hybrid quantum autoencoder (2021). arXiv: 2107.11988.

5 Feed Forward Network

ffNN

F. Tacchino, S. Mangini, P. K. Barkoutsos, C. Macchiavello, D. Gerace, I. Tavernelli, D. Bajoni, Variational learning for quantum artificial neural networks, IEEE Transactions on Quantum Engineering 2 (2021) 1–10.

F. Tacchino, P. Barkoutsos, C. Macchiavello, I. Tavernelli, D. Gerace, D. Bajoni, Quantum implementation of an artificial feed-forward neural network, Quantum Science and Technology 5 (4) (oct 2020). arXiv:1912.12486

6 CNN Convolutional Network

Orthogonal neural networks

K. Jia, S. Li, Y. Wen, T. Liu, D. Tao, Orthogonal deep neural networks (2019). arXiv:1905.05929.

J. Wang, Y. Chen, R. Chakraborty, S. X. Yu, Orthogonal convolutional neural networks (2020). arXiv:1911.12207.

I. Kerenidis, J. Landman, N. Mathur, Classical and quantum algorithms for orthogonal neural networks (2021). arXiv:2106.07198.

QDCNN

Y. Li, R. G. Zhou, R. Xu, J. Luo, W. Hu, A quantum deep convolutional neural network for image recognition, Quantum Science and Technology 5 (4) (oct 2020).

7 RNN:Recurrent Neural Network/LSTM

LSTM-QNN

H. Wang, J. Zhao, B. Wang, L. Tong, A quantum approximate optimization algorithm with metalearning for maxcut problem and its simulation via tensorflow quantum, Mathematical Problems in Engineering 2021 (2021)..C. P. Gonçalves, Quantum neural machine learning: Backpropagation and dynamics, NeuroQuantology 15 (1) (2017) 22–41. arXiv: 1609.06935

QRNN(Quantum Recurrent Neural Network)

B. Q. Chen, X. F. Niu, Quantum Neural Network with Improved Quantum Learning Algorithm, International Journal of Theoretical Physics 59 (7) (2020) 1978–1991.

F. Tacchino, S. Mangini, P. K. Barkoutsos, C. Macchiavello, D. Gerace, I. Tavernelli, D. Bajoni, Variational learning for quantum artificial neural networks, IEEE Transactions on Quantum Engineering 2 (2021) 1–10

8 ベイジアン

Quantum Naive Bayes

Quantum speedup of Bayes' classifiers Shao, C. (2020). Quantum speedup of Bayes' classifiers. Journal of Physics A, 53, [045301].

9 GAN

qGAN

H. Situ, Z. He, Y. Wang, L. Li, S. Zheng, Quantum generative adversarial network for generating discrete distribution, Information Sciences 538 (2020) 193–208. arXiv:1807.01235

W. Liu, Y. Zhang, Z. Deng, J. Zhao, L. Tong, A hybrid quantum-classical conditional generative adversarial network algorithm for human-centered paradigm in cloud, Eurasip Journal on Wireless Communications and Networking 2021 (1) (dec 2021)

A. Anand, J. Romero, M. Degroote, A. Aspuru-Guzik, Noise Robustness and Experimental Demonstration of a Quantum Generative Adversarial Network for Continuous Distributions, Advanced Quantum Technologies (may 2021). arXiv:2006.01976

1 できること

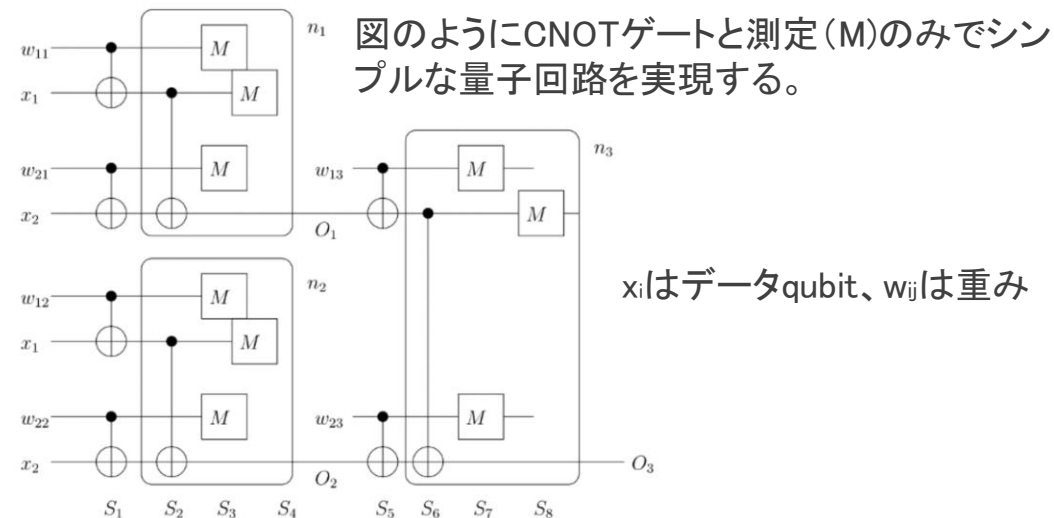
CNOT Neural Networksは量子ニューラルネットワークの一つである。その主な目的は、必要な計算の複雑さを軽減し、さまざまな計算要素の数を最小限に抑えることを可能にする。この目的を達成するために、離散ブール関数のみが設計され、単純な伝達関数を備えたより多くの層を持つモデルが利用できる。

2 アルゴリズム解説

量子ニューラルネットワークモデルは存在するが、それらの計算の複雑さは、ニューロンの活性化関数をシミュレートするための特定のユニタリ変換、または目的の変換を実行するための多数の補助量子ビットを必要とする場合がある。これらの問題のいくつかを解決するために、CNOT Neural Networksと呼ばれる量子ニューラルネットワークモデルが提案されている。

CNOT Neural Networksは、CNOT量子ゲートと測定演算子のみを使用する。これらは、あらゆる量子コンピューティング技術で非常に簡単に実装できる。CNOT Neural Networksは、これら2つの単純な演算子のみを使用して、最適化された学習率と一定数の補助量子ビットを維持しながら、ANDやORなどのユニバーサル演算子に対応できる。

3 量子回路



4 特徴、古典的手法に対するアドバンテージなど

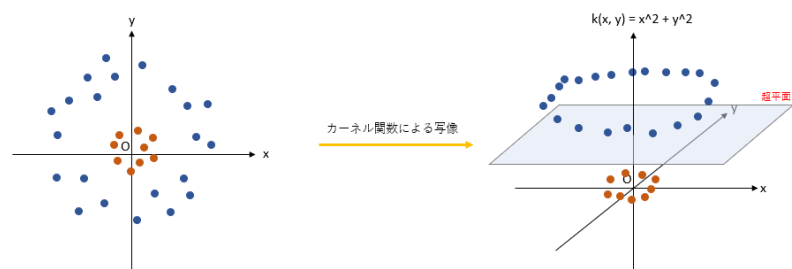
提案されたモデルの主な目的は、必要な計算の複雑さを軽減し、さまざまな計算要素の数を最小限に抑えることを可能にして計算時間の削減とエラー発生の可能性を軽減する。

5 オリジナル・関連論文

M. Lukac, K. Abdiyeva, M. Kameyama, CNOT-measure quantum neural networks, in: Proceedings of The International Symposium on Multiple-Valued Logic, Vol. 2018-May, IEEE Computer Society, 2018, pp. 186-191. doi:10.1109/ISMVL.2018.00040.

1 概要

SVM(サポートベクターマシン)とは、2クラス分類の線形関数を構築する機械学習モデルの一種である。
 応用理論として、「カーネル関数」を用いた特徴量の高次元への写像を行うことで、非線形分離を実現する。



非線形のことを次元を増やすことで線形に分離できる。

QSVMは、次の「カーネル関数」を使用する点に特徴がある。

2 アルゴリズム解説

QSVMでは、カーネル関数を以下のように定義する。

$$K(x_i, x_j) = |\langle \Phi(x_i) | \Phi(x_j) \rangle|^2$$


※ x_i, x_j は入力データであり、データ間の全組合せ

この絶対値の中身は $|\Phi(x)\rangle$ の内積となっている。

ここで $|\Phi(x)\rangle$ は何らかの量子状態を意味し、以下のようにユニタリ展開を用いて以下の状態を生成する。

1量子ビットの場合

$$U(x)|0\rangle = |\Phi(x)\rangle$$




3 量子回路

特徴量が2つで、入力データ $x=(x_1, x_2)$ に対して、 $U(x)$ は2次オーダーまでの展開で次のように書くことができる。

$$U(x) = \left(e^{i(x_1 z_1 + x_2 z_2 + (\pi - x_1)(\pi - x_2) z_1 z_2)} H^{\otimes 2} \right)^l$$

ここで l は回路の深さ(depth)と呼ばれる量で、増やすことで精度が向上するとされている。回路で表現すると以下のような形となる。



4 古典的手法に対するアドバンテージ

回路の深さが一定以上の場合、計算時間、モデル性能の両面において、古典的手法に対しアドバンテージが期待できる。

5 オリジナル・関連論文


- Vojtech Havlicek et al., Supervised learning with quantum enhanced feature spaces, <https://arxiv.org/pdf/1804.11326.pdf>
- [Qiskitで量子SVMを実装して性能評価してみた - Qiita](#)
- [量子SVMの基本 - IBM Qiskit SVM\(QSVM\)を実装し、線形・非線形の基本的な2クラス分類機能を確認する - Qiita](#)

1 できること

Reservoir ComputingはRNNの一種と考えられており、時系列処理を行うことができる。そしてReservoir Computingは入力層、中間(Reservoir)層、出力層の3層からなっている。

Reservoir特有の特徴としては入力層とReservoir層において重みの更新が行われない点である。Reservoir Computingでは出力だけを線型回帰によって学習することで学習が安定的に行えるため、ネットワークの規模を大きくすることができるので、結果として線型回帰だけでもRNNに匹敵する性能が期待できる。

Quantum Reservoir ComputingはReservoir Computingの量子版であり、より少ない量子ビットで古典方式の大規模な計算を行うことができることが特徴である。



2 アルゴリズム解説

Quantum Reservoir Computing(QRC)は、動的システムを使用して、時系列処理を実行する。このタスクの主な目的は予測であり、シーケンス(時系列)を時系列予測とパターン分類のためのターゲット出力シーケンスに変換する関数を作成することである。QRCフレームワークでは、動的システムは次の式で与えられる。

$$\rho_t = T_{u_t}(\rho_{t-1}),$$

ここで、 ρ_t は、時間 t での状態を表す密度演算子であり、 T_{u_t} は、入力依存で完全に正のトレース保存マップ(CPTP)であるQRCの時間発展を表すシステムである。CPTPマップは次の式で与えられる。

$$\rho_t = e^{-iH\tau}(\rho_{input} \otimes Tr_{input}(\rho_{t-1}))e^{iH\tau},$$

補助キュービットは入力値 $u_t \in [0,1]$ を取り、システム全体が入力に依存しないユニタリ演算子 $e^{-iH\tau}$ によって時間内に変換される。ここで、

$$\rho_{input} = |\psi_{u_t}\rangle\langle\psi_{u_t}| \text{ with } |\psi_{u_t}\rangle = \sqrt{1-u_t}|0\rangle\langle 0| + \sqrt{u_t}|1\rangle\langle 1|$$

である。

3 特徴、古典的手法に対するアドバンテージなど

QRCでは、ハミルトニアンのパラメータなどを調整する必要がなく、量子多体系の複雑なアナログダイナミクスをそのまま計算リソースとして利用することができる。5-7量子ビットからなる量子系(ランダム結合の横磁場イジング模型)であっても、100-500ノードの古典的Reservoir Computingと同等の計算能力があることで古典手法に対してアドバンテージがある。

4 関連論文

- [Quantum reservoir processing](#)
- [Quantum reservoir computing: a reservoir approach toward quantum machine learning on near-term quantum devices](#)
- [量子レザバーコンピューティング 量子実時間ダイナミクスの機械学習への応用](#)
- [Boosting computational power through spatial multiplexing in quantum reservoir computing](#)

1 できること

従来の教師ありニューラルネットワークは、強制終了による収束の問題とセグメンテーションの精度の低下がある。

Quantum Fully Self-Supervised Neural Networks (QFS-Net)は洗練された3段階で構成されるキュートリットからなる量子情報システムを活用する新しい教師ありニューラルネットワークモデルである。

2 アルゴリズム解説

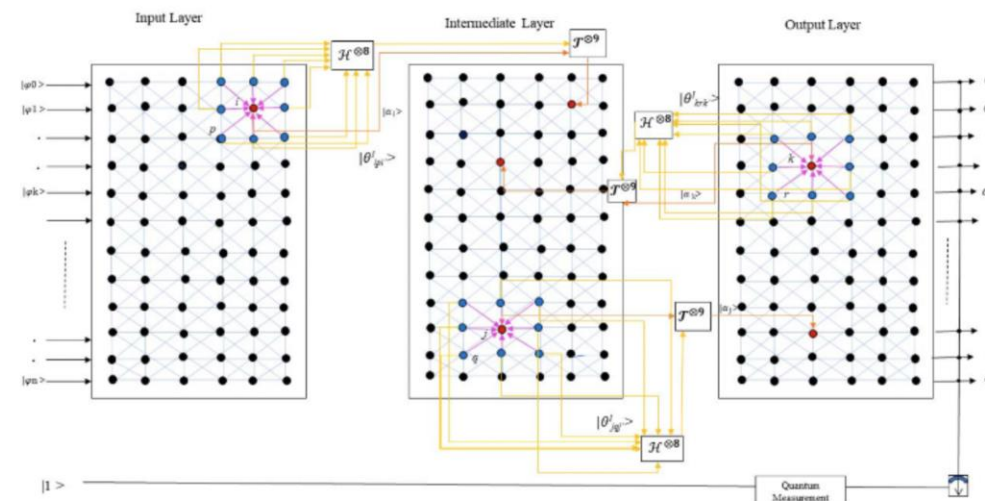
QFS-Netモデルは、8接続された2次近隣ベースのトポロジを使用して、パラメトリックアダマールゲートを介して相互接続されたキュートリットの層状構造の三位一体で構成される。

キュートリット状態の非線形変換により、基礎となる量子ニューラルネットワークモデルが量子状態をエンコードできるようになり、監視なしで層間のこれらの状態のより高速な自己組織化された逆伝播が可能になる。

3 量子回路

QFS-Networkの情報処理ユニットはキュートリットである。各層のキュートリットニューロンは、変換ゲートTを使用して取得され、相互接続の重みは、アダマールゲート(H)を使用してキュートリットにマッピングされる。回転角(図のピンク色の矢印)は、各候補キュートリットニューロンと、回転ゲートで使用する同じレイヤーの隣接するキュートリットニューロンとの間の情報の相対差を取得して、レイヤー間の相互接続を更新することによって調整される。新しいシグモイド活性化関数は、QFSネットワークの自己伝播および逆伝播メカニズムをガイドする。

以下はキュートリットの量子回路である。



4 特徴、古典的手法に対するアドバンテージなど

QFS-Netはキュートリットからなる量子情報により従来の課題であたちあ収束の問題とセグメンテーションの精度の低下の問題を回避する。

5 オリジナル・関連論文

D. Konar, S. Bhattacharyya, B. K. Panigrahi, E. C. Behrman, Qutrit-Inspired Fully Self-Supervised Shallow Quantum Learning Network for Brain Tumor Segmentation, IEEE Transactions on Neural Networks and Learning Systems (2021) 1–15arXiv:2009.06767

1 できること

古典K-meansのアルゴリズムで「距離」を計算する部分を量子コンピューターに置き換えることで、計算量を少なくする

2 アルゴリズム解説

-古典アルゴリズム-

以下の流れに沿って行う

- ① K個のクラスターの個々に代表点を決める(初期化)
- ② N個のデータを最も距離が近い代表点に割り当てる
- ③ 割り当てたデータをグループ毎に平均することで代表点を計算し直す
- ④ 更新量が小さくなるまでこの②と③を繰り返す
(個々のデータのグループが移動しなくなるまで)

-量子アルゴリズム-

②, ③において
データに対応する
量子状態の内積を
用いて距離を表現





図: <https://hogetech.info/machine-learning/algorithm/kmeans>

3 量子回路

データ間の「距離」を求めるには、SWAPテストを利用する。



4 古典的手法に対するアドバンテージ

特徴ベクトル数をmとすると

古典での距離計算量 $O(m)$ → 量子での距離計算量 $O(\log m)$

5 オリジナル・関連論文

Khan, Sumsam Ullah, Ahsan Javed Awan, and Gemma Vall-Llosera.
“K-means clustering on noisy intermediate scale quantum computers.” *arXiv preprint arXiv:1909.12183* (2019).

1 できること

PCA (Principal Analysis) は、従来より統計学で用いられる手法で、次元数の多いデータから、主要な変数を抽出するものである。近年では機械学習の分野において、次元数の多いデータからその特徴を継承しながら、次元を削減したデータを抽出する次元削減の手法として活用されている。qPCAはその量子版である。

2 アルゴリズム解説

PCAではN次元の入力データから共分散行列を構成し、固有分解を行い、R次元データを結果として得る。量子版では共分散行列と密度行列を同一視し、密度行列の指数関数をとったものについて固有値、固有ベクトルの計算を行う。

おもなアルゴリズムは以下のとおりである。

1. 入力データの単純化と正規化

N次元の入力データ $x^{(i)}, i = 1, \dots, M$ について、M個のデータの平均値をもとめ、各 $x^{(i)}$ から引く。また、各 $x^{(i)}$ をそれぞれのベクトルの長さで割り、正規化する。

2. 古典データの量子状態へのエンコード

$x^{(i)}$ の要素 $x_k, k = 1, \dots, N$ について、量子状態の振幅にエンコードする：

$$x \longrightarrow |x\rangle = \sum_{k=1}^N x_k |k\rangle$$

3. 共分散行列を構成する。共分散行列は密度行列と同一視する。

$$\rho = \frac{1}{M} \sum_{i=1}^M |x^{(i)}\rangle \langle x^{(i)}|$$

4. 密度行列の指数関数を構成する

密度行列の固有値、固有ベクトルを求めるのに、量子位相推定のアルゴリズムを用いる。量子位相推定のインプットはユニタリ行列となっている。一般に密度行列はエルミートであるが、ユニタリではない。ここで、 $U = e^{i\rho}$ とすると U はユニタリ行列となるため、このように変換した行列に量子位相推定を適用する。

5. 密度行列の指数関数の固有分解を行う

実際にはパラメタ t を付した $U = e^{-i\rho t}$ について、量子位相推定により、M個の固有値 $\lambda^{(i)}$ 、固有ベクトル $|\phi^{(i)}\rangle$ を求める。

6. 主成分およびスコアの計算

第j番目の主成分 $S^{(j)}$ は以下のように求められる：

$$S^{(j)} = [s_1^{(j)}, s_1^{(j)}, \dots, s_M^{(j)}]^T$$

ここで

$$s_i^{(j)} = \sum_{k=1}^N x_k^{(i)} \phi_k^{(j)}$$

$S^{(j)}$ は対応する固有値 $\lambda^{(i)}$ の最大値から降順にR個 ($R \ll N$) を使い、次元削減を行う。なお、量子回路は紙面の都合上、省略した。

3 特徴、古典的手法に対するアドバンテージなど

古典での計算量は $O(N)$ であり、量子では $O(R \log N)$ である。固有値計算において、量子の計算量が古典に比較して減少するアドバンテージがある。

qPCAは古典の入力データをエンコードする量子計算の前処理などがある。これらの処理の計算量によっては、固有値計算の計算量でのメリットを打ち消してしまう可能性がある。なお、エンコード処理は古典から量子にデータを移す場合の一般的な課題である。

4 関連論文

- Kopczyk, Quantum machine learning for data scientists, <https://arxiv.org/abs/1804.10068>, 2018.
- Lloyd et al., Quantum principal component analysis, <https://arxiv.org/abs/1307.0401>, 2013.

1 できること

量子ベイジアンネットワークは、ベイジアンネットワークを元として、そのノードに対する確率を量子ビットの確率振幅に乗せて量子回路で計算することでベイジアンネットワークの確率計算を高速化できる。


2 アルゴリズム解説

以下のように、ベイジアンネットワークのすべての変数のノードに対する確率を量子回路に落とし込み確率計算を高速化します。

- ① ベイジアンネットワークでの変数の親ノードあるいはルートノードを量子回路の入力にする。
- ② 変数のノードに対する確率は親ノードあるいは子ノードの相互作用によって発生すると想定し、その相互作用をとフォリゲートのようなマルチ制御ユニタリゲートで表現。
- ③ 探索目的である変数の確率を全体的な確率振幅として出力するように量子回路を構成する。

【例:乗客の性別(Sex)と子供であること(isChild)がタイタニック号の生存者(Survival)に与えた影響のベイジアンネットワークの場合】

- ① 左図のような3ノードベイジアンネットワークを考える。各ノードはキュービットで表され、ノードSex、isChild、Survivalそれぞれ1量子ビットとして扱う。
- ② 量子ビットの状態は、量子状態 $|0\rangle$ を成人男性または単に成人の乗客として、状態 $|1\rangle$ を成人女性または子供と扱い、Sexノード、isChildノードの確率振幅で表現する。
- ③ 最後に探索目的であるSurvivalノードの確率条件を、量子回路として実装することで、探索目的の条件での発生確率を確率振幅として示すことができる。



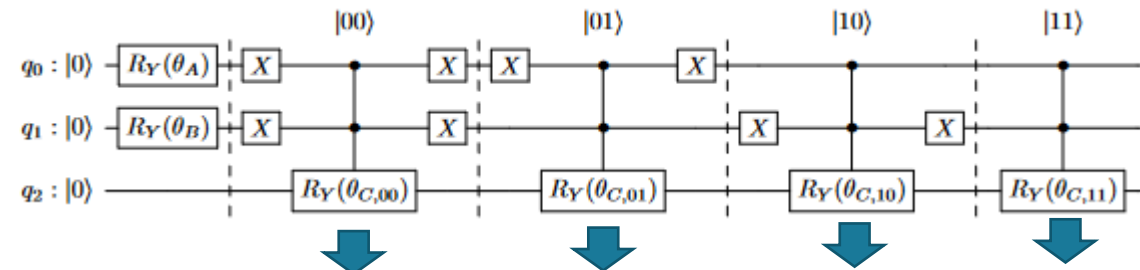
① 図1:ベイジアンネットワーク図

- ② $\psi_{Sex} = \sqrt{P(male)}|0\rangle + \sqrt{P(female)}|1\rangle$
 $\psi_{isChild} = \sqrt{P(adult)}|0\rangle + \sqrt{P(child)}|1\rangle$

③ $|\psi_{Sex}\rangle|\psi_{isChild}\rangle \xrightarrow{\text{量子回路}} |\psi_{Surv}\rangle$

3 量子回路

一般的に3ノードベイジアンネットワークの量子回路は以下のとおり。



$|q_2\rangle$ は $|00\rangle$ または、 $|01\rangle$ または、 $|10\rangle$ または、 $|11\rangle$ の条件結果を表現し、 $|0\rangle$ か $|1\rangle$ の真理値として結果を返し、その確率振幅はそれぞれの条件の発生確率として示される。

図2: ベイジアンネットワークの量子回路例

※左記のアルゴリズム例としては、以下読替えると量子回路化できる。

$$\begin{aligned}
 R_Y(\theta_A) &\rightarrow R_Y(\theta_{child}) & R_Y(\theta_B) &\rightarrow R_Y(\theta_{female}) \\
 R_Y(\theta_{C,00}) &\rightarrow R_Y(\theta_{Surv,male\&adult}) & R_Y(\theta_{C,01}) &\rightarrow R_Y(\theta_{Surv,male\&child}) \\
 R_Y(\theta_{C,10}) &\rightarrow R_Y(\theta_{Surv,female\&adult}) & R_Y(\theta_{C,11}) &\rightarrow R_Y(\theta_{Surv,female\&child})
 \end{aligned}$$

4 古典的手法に対するアドバンテージ

計算回数の多いベイジアンネットワークをそのアルゴリズムのイメージを壊さず高速で計算できる。

5 オリジナル・関連論文

- Quantum circuit representation of Bayesian networks (<https://doi.org/10.48550/arXiv.2004.14803>)
- Hands-On Quantum Machine Learning With Python
- Create A Quantum Bayesian Network | by Frank Zickert

1 できること

qLiNGAMは、量子因果探索である。
 複数の変数間の因果関係を数値化をする。
 古典では発見できない因果関係の発見や、少数のデータでの正しい因果関係の算出が可能とされる。

2 アルゴリズム解説

量子カーネル G_X, G_Y を使用(古典ではガウスカーネル)することで
 独立性指標 $I_n^{NOCCO}(X, Y)$ の計算し因果グラフを作成

$$I_n^{NOCCO}(X, Y) = \text{Tr}[R_Y R_X]$$

$$R_Y = G_Y(G_Y + n\epsilon_n I_n)^{-1}, R_X = G_X(G_X + n\epsilon_n I_n)^{-1}$$

n : サンプル数, ϵ_n : 規格化定数, I_n : 単位行列

(*e.g.*) $X, Y \in \{sex, isChild, Survival\}$

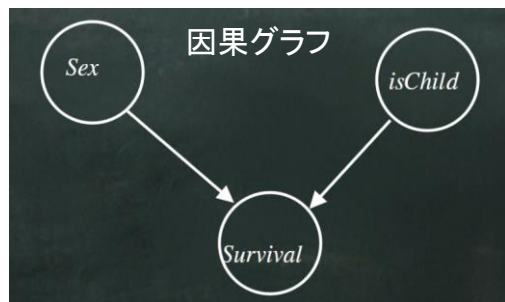
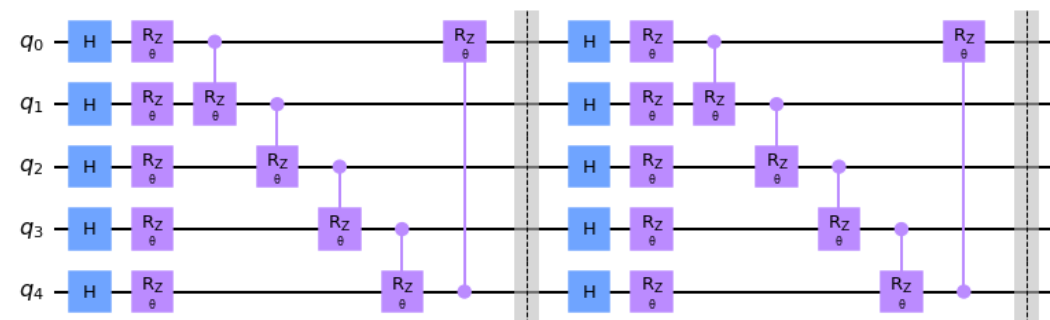


図: <https://towardsdatascience.com/create-a-quantum-bayesian-network-d26d7c5c4217>

3 量子回路



量子カーネル構築における特徴量エンコーディング
 ・5量子ビットの回路に対して1つのパラメータをエンコード
 ・エンタングル形式は循環型
 ・古典模倣困難性を有する量子回路とされるIQP*回路を採用
 (*Instantaneous Quantum Polynomial time circuit)

4 古典的手法に対するアドバンテージ

古典では発見できない因果関係の発見や
 少数のデータでの正しい因果関係の算出が可能と示唆

5 オリジナル・関連論文

Kawaguchi, Hideaki. "Application of quantum computing to a linear non-Gaussian acyclic model for novel medical knowledge discovery." *arXiv preprint arXiv:2110.04485* (2021).

本資料の著作権は、日本アイ・ビー・エム株式会社（IBM Corporationを含み、以下、IBMといいます。）に帰属します。

ワークショップ、セッション、および資料は、IBMまたはセッション発表者によって準備され、それぞれ独自の見解を反映したものです。それらは情報提供の目的のみで提供されており、いかなる参加者に対しても法律的またはその他の指導や助言を意図したものではなく、またそのような結果を生むものでもありません。本資料に含まれている情報については、完全性と正確性を期するよう努力しましたが、「現状のまま」提供され、明示または暗示にかかわらずいかなる保証も伴わないものとします。本資料またはその他の資料の使用によって、あるいはその他の関連によって、いかなる損害が生じた場合も、IBMまたはセッション発表者は責任を負わないものとします。本資料に含まれている内容は、IBMまたはそのサプライヤーやライセンス交付者からいかなる保証または表明を引きだすことを意図したものでも、IBMソフトウェアの使用を規定する適用ライセンス契約の条項を変更することを意図したものでもなく、またそのような結果を生むものでもありません。

本資料でIBM製品、プログラム、またはサービスに言及していても、IBMが営業活動を行っているすべての国でそれらが使用可能であることを暗示するものではありません。本資料で言及している製品リリース日付や製品機能は、市場機会またはその他の要因に基づいてIBM独自の決定権をもっていつでも変更できるものとし、いかなる方法においても将来の製品または機能が使用可能になると確約することを意図したものではありません。本資料に含まれている内容は、参加者が開始する活動によって特定の販売、売上高の向上、またはその他の結果が生じると述べる、または暗示することを意図したものでも、またそのような結果を生むものでもありません。パフォーマンスは、管理された環境において標準的なIBMベンチマークを使用した測定と予測に基づいています。ユーザーが経験する実際のスループットやパフォーマンスは、ユーザーのジョブ・ストリームにおけるマルチプログラミングの量、入出力構成、ストレージ構成、および処理されるワークロードなどの考慮事項を含む、数多くの要因に応じて変化します。したがって、個々のユーザーがここで述べられているものと同様の結果を得られると確約するものではありません。

記述されているすべてのお客様事例は、それらのお客様がどのようにIBM製品を使用したか、またそれらのお客様が達成した結果の実例として示されたものです。実際の環境コストおよびパフォーマンス特性は、お客様ごとに異なる場合があります。

IBM、IBM ロゴは、米国やその他の国におけるInternational Business Machines Corporationの商標または登録商標です。他の製品名およびサービス名等は、それぞれIBMまたは各社の商標である場合があります。現時点でのIBMの商標リストについては、ibm.com/trademarkをご覧ください。